Introduction à la Computer Vision

Computer Vision - Séance 1

1. Définition de la Computer Vision

La **Computer Vision** (vision par ordinateur) est un domaine de l'intelligence artificielle dont l'objectif est de permettre aux machines **d'acquérir, traiter, analyser et interpréter des images ou des vidéos**, afin d'en extraire des informations utiles ou de prendre des décisions.

Elle vise à répondre à des questions telles que :

- Que contient cette image ?
- Où se trouvent les objets d'intérêt ?
- Que se passe-t-il dans cette scène ?
- Comment cette scène évolue-t-elle dans le temps ?

1. Définition de la Computer Vision

La Computer Vision se situe à l'intersection de plusieurs disciplines :

- Traitement du signal et de l'image
- Mathématiques (algèbre linéaire, probabilités)
- Apprentissage automatique et deep learning
- Informatique (algorithmie, structures de données)

Contrairement à la vision humaine, **la machine ne "voit" pas**, mais manipule des **valeurs numériques** représentant l'intensité lumineuse captée par un capteur.

2. Cas d’usage

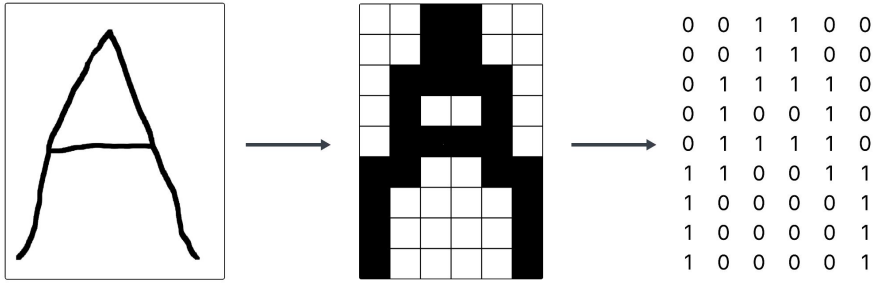
0 0 1 1 0 0
0 0 1 1 0 0
0 1 1 1 1 0
0 1 0 0 1 0
0 1 1 1 1 0
1 1 0 0 1 1
1 0 0 0 0 1
1 0 0 0 0 1
1 0 0 0 0 1
(a)
(b)
(c)

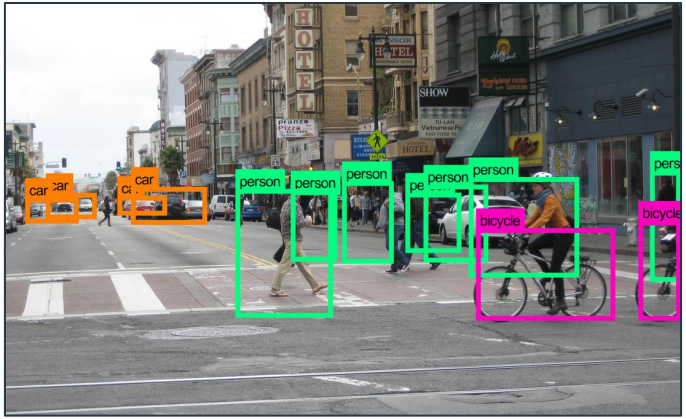
car
person
bicycle
HOTEL
SHOW

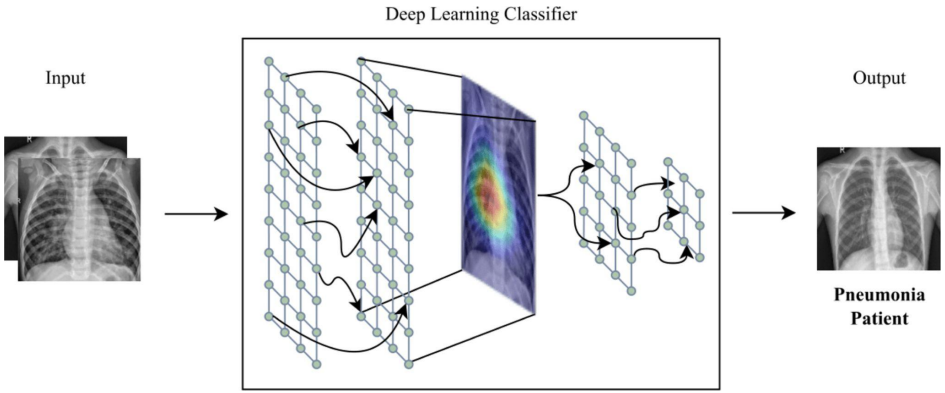
Deep Learning Classifier
Input
Output
Pneumonia
Patient

2.1 OCR – Optical Character Recognition

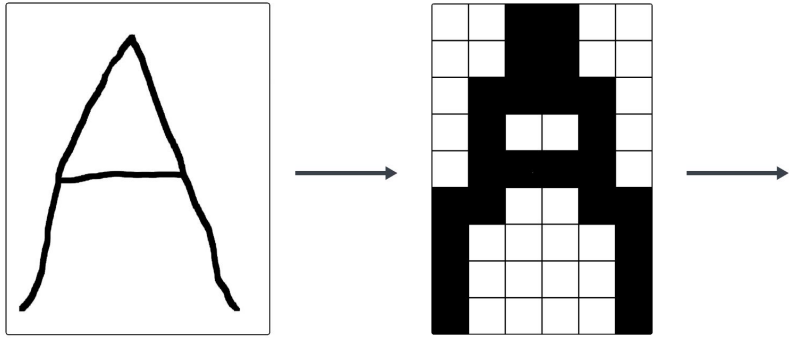

(a) (b) (c)

L'OCR consiste à **détecter et reconnaître du texte présent dans des images** ou des documents scannés.

Applications :

- Dématérialisation de documents administratifs
- Lecture automatique de factures et formulaires
- Reconnaissance de plaques d'immatriculation
- Extraction d'informations dans les documents juridiques ou bancaires

Défis spécifiques :

- Variabilité des polices
- Qualité d'image variable
- Texte manuscrit
- Mise en page complexe

2.2 Vidéosurveillance et sécurité

La vision par ordinateur est largement utilisée pour :

- Détection et suivi de personnes
- Reconnaissance faciale
- Détection de comportements anormaux
- Comptage de flux (personnes, véhicules)

Contraintes fortes :

- Temps réel
- Robustesse aux variations de luminosité
- Problématiques éthiques et réglementaires (RGPD)

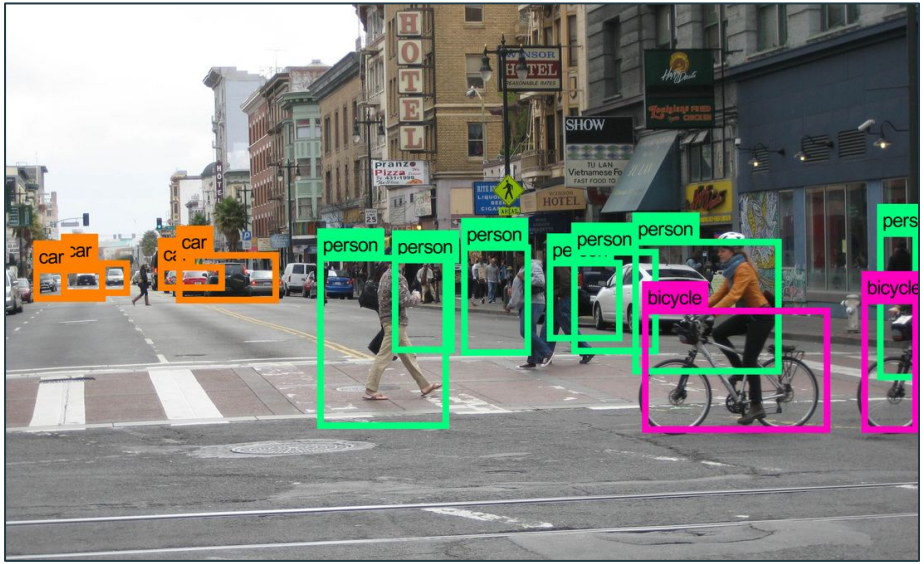

2.3 Domaine médical

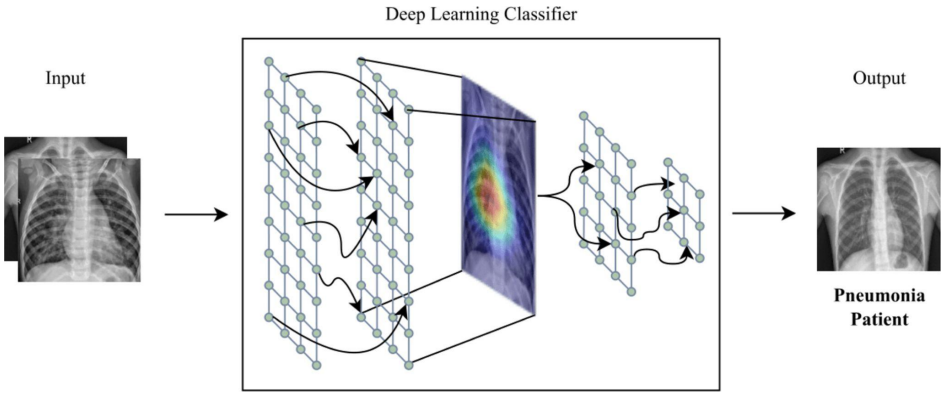

La Computer Vision joue un rôle clé dans l'**aide au diagnostic médical**.

Exemples :

- Détection de tumeurs sur IRM ou scanners
- Analyse d'images histologiques
- Détection de fractures sur radiographies
- Suivi de l'évolution d'une pathologie

Spécificités :

- Données sensibles et rares
- Fort besoin de précision
- Interprétabilité des modèles

2.4 Retail et e-commerce

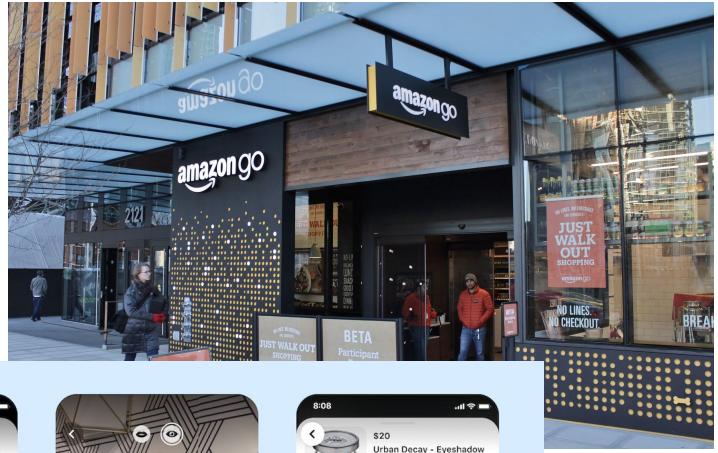

Dans le commerce, la vision est utilisée pour :

- Reconnaissance de produits
- Analyse du comportement client
- Gestion automatique des stocks
- Caisses sans contact

Exemples concrets :

- Détection de rupture de stock en rayon
- Analyse de parcours client
- Recherche visuelle de produits

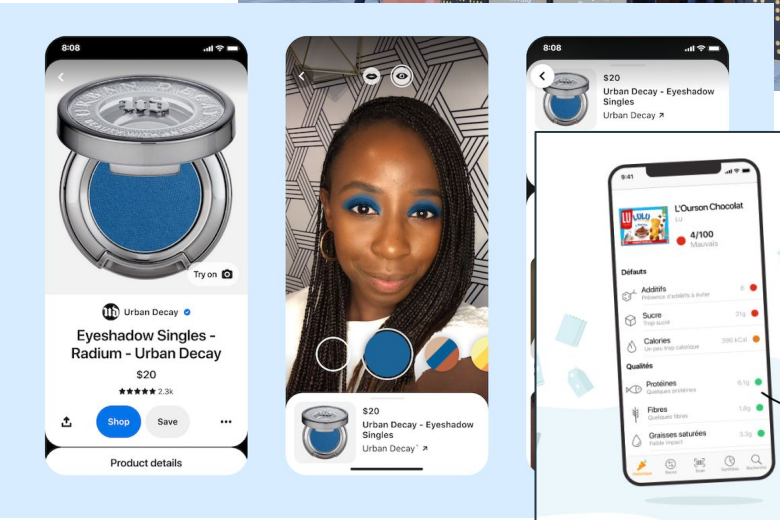

2.5 Automobile et mobilité

La vision est au cœur des **véhicules autonomes et ADAS**.

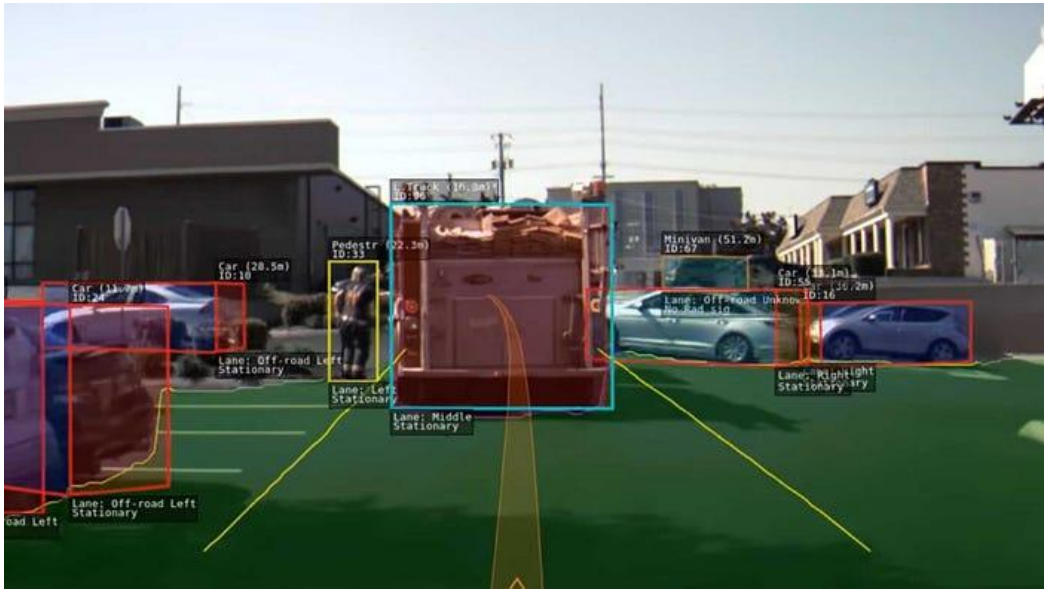

Fonctionnalités :

- - Détection de piétons et véhicules
- - Reconnaissance des panneaux de signalisation
- - Suivi de voie
- - Estimation de profondeur et de distance

Contraintes :

- - Temps réel
- - Sécurité critique
- - Conditions météo variables

2.6 méthode de l'état de l'art

Les descripteurs :

- Edge Orientation Histograms (EOH)
- Les ondelettes de Haar
- Local Binary Pattern LBP
- Histogramme Orienté du Gradient

les classifieurs :

- Machine à vecteurs de support SVM
- AdaBoost
- Réseaux de neurones

Modèle utilisé :

- deepseek-ai/DeepSeek-OCR
- rednote-hilab/dots.ocr
- nvidia/nemotron-ocr-v1
- nanonets/Nanonets-OCR2-3B

pour aller plus loin :

- Détection et suivi de personnes par vision omnidirectionnelle: approches 2D et 3D
- Tuto : Détection de personnes dans une vidéo

3. Représentation d’une image

3.1 Image binaire

Une image numérique est une **matrice de valeurs numériques** représentant l'intensité lumineuse mesurée par un capteur.

Chaque élément de la matrice correspond à un **pixel**.

$$I \in \mathbb{R}^{H \times W}$$

- H : hauteur
- W : largeur
- Chaque pixel représente une intensité (ex. 0 à 255)

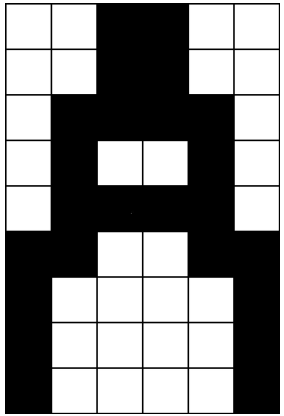

3.2 Image couleur (RGB)

Une image couleur est composée de **trois canaux** :

- Rouge (R)
- Vert (G)
- Bleu (B)

Elle est représentée par un tenseur 3D :

$$I \in \mathbb{R}^{H \times W \times 3}$$

Chaque canal contient une matrice d'intensités.

Pour illustrer nous allons représenter nos faisceaux comme des pixel d'une image et chaque pixel va être représenter par un vecteur RGB.

cela nous donne une matrice 30x30 de vecteur RGB, dont la première ligne serait :

[[255,255,255],[255,255,255],[255,255,255],[255,255,255],[255,255,255],[0,0,0],[0,0,0],[0,0,0],[0,0,0],[0,0,0],[0,0,0],[0,0,0],[255,255,0],[255,255,0],[255,255,0],[255,255,0]], …

cette représentation permet notamment via des algorithmes d'effectuer de la reconnaissance de motif dans des images.

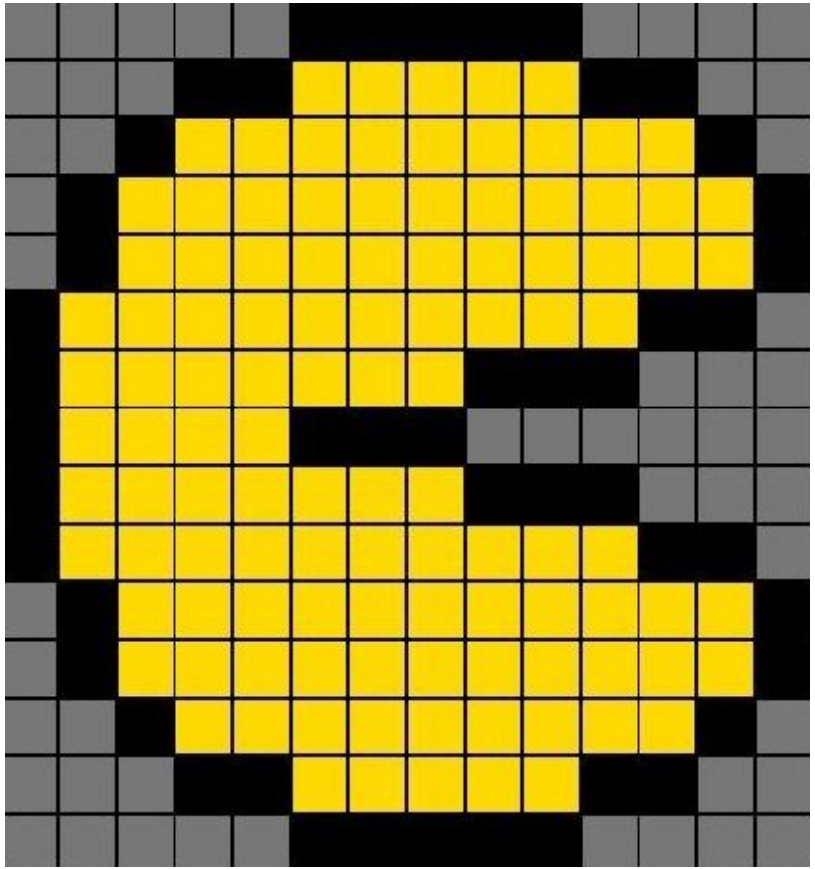

3.3 Images et tenseurs en Deep Learning

Dans les frameworks de deep learning, les images sont souvent représentées sous forme de tenseurs :

$$\text{Batch} \times \text{Canaux} \times \text{Hauteur} \times \text{Largeur}$$

- **Batch** : Nombre d'images traitées simultanément (ex: 32 images envoyées au GPU en parallèle pour accélérer l'entraînement)
- **Canaux** : Composantes de couleur de l'image (3 pour RGB, 1 pour niveaux de gris, 4 pour RGBA)

Exemple PyTorch :

python

```python
tensor.shape = (32, 3, 224, 224)
```

- - 32 images
- - 3 canaux
- - Résolution 224×224

4. Présentation d'un pipeline de traitement de l'image

4.1 Conversion en niveaux de gris

La plupart des algorithmes de contours travaillent sur une **image 2D** (intensité).

$$I_{gray} = 0.299R + 0.587G + 0.114B$$

Pourquoi ?

- - Réduction de la complexité
- - Suppression d'informations non pertinentes pour les gradients

Coefficients (Standard ITU-R BT.601) :

Couleur	Coefficient	Sensibilité de l'œil humain
Rouge (R)	0.299	Moyenne
Vert (G)	0.587	Très élevée
Bleu (B)	0.114	Faible

4.2 Réduction du bruit (Denoising)

Type de bruit	Description	Apparence
Gaussien	Distribution normale autour de la vraie valeur	Grain uniforme
Sel & Poivre	Pixels aléatoirement blancs (255) ou noirs (0)	Points isolés
Poisson	Lié au comptage de photons (faible luminosité)	Grain variable

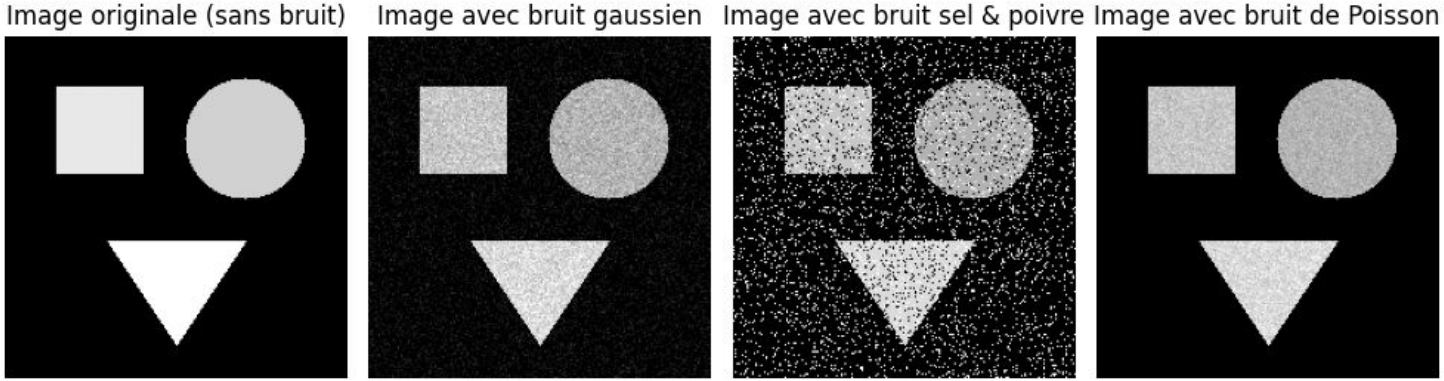

4.2.1 Flou Gaussien (Gaussian Blur)

Principe mathématique

Le filtre gaussien applique une **convolution** avec un noyau dont les poids suivent une distribution gaussienne 2D :

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

Où :

- (x, y) : distance au centre du noyau
- σ (sigma) : écart-type, contrôle l'étalement du flou

Paramètre	Effet
Taille du kernel	Doit être impair (3, 5, 7...). Plus grand = plus de flou
Sigma (σ)	Plus élevé = distribution plus étalée = plus de lissage

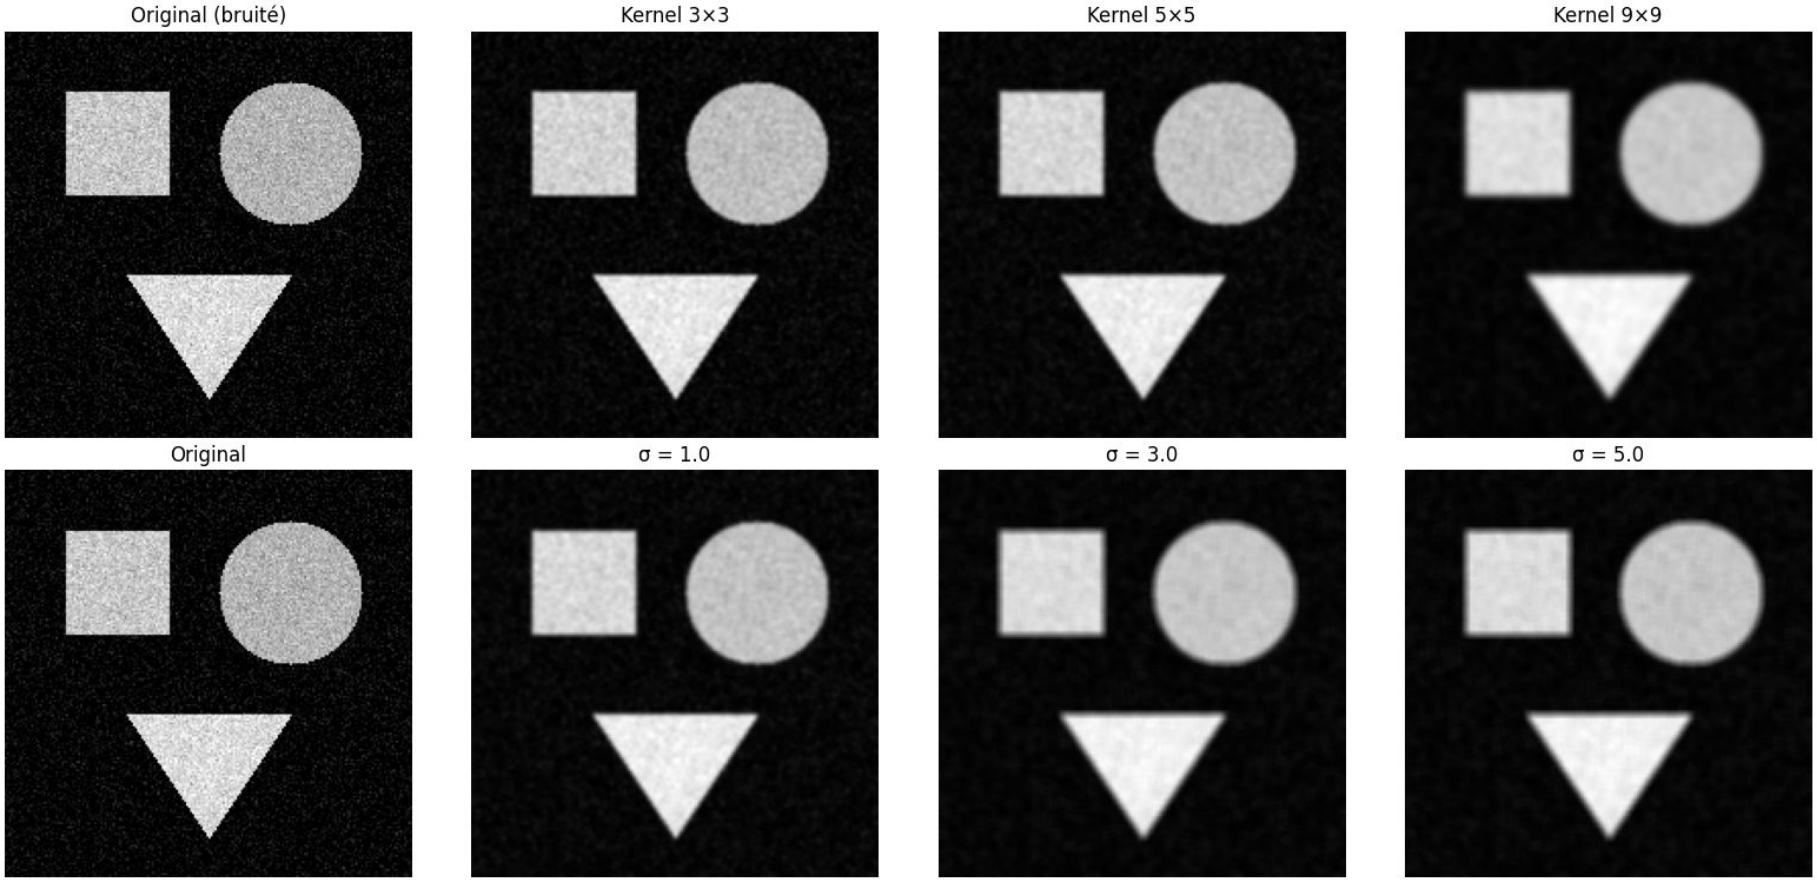
Flou Gaussien : Impact de la taille du kernel et de σ
Original (bruité)
Kernel 3×3
Kernel 5×5
Kernel 9×9
Original
σ = 1.0
σ = 3.0
σ = 5.0

4.2.2 Filtre médian

Principe

Pour chaque pixel :

1. Prendre tous les pixels du **voisinage** (ex: 3×3)
2. **Trier** les valeurs
3. 3. Remplacer par la **valeur médiane**

Avantage

- Très efficace contre le bruit impulsionnel (sel & poivre)
- Préserve mieux les contours que le flou gaussien

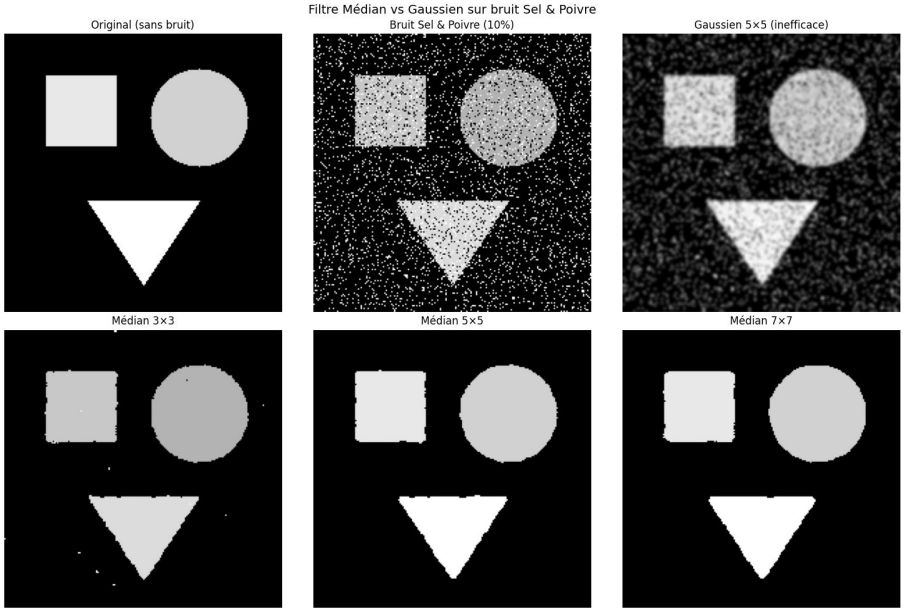

Voisinage 3×3 : Valeurs triées :

| 120 130 125 | [5, 120, 122, 125, 126, 128, 130, 132, 255]

| 126 255 128 | → Médiane = 126

| 122 132 5 |

Le pixel 255 (bruit) est remplacé par 126

4.2.3 Bilateral Filter

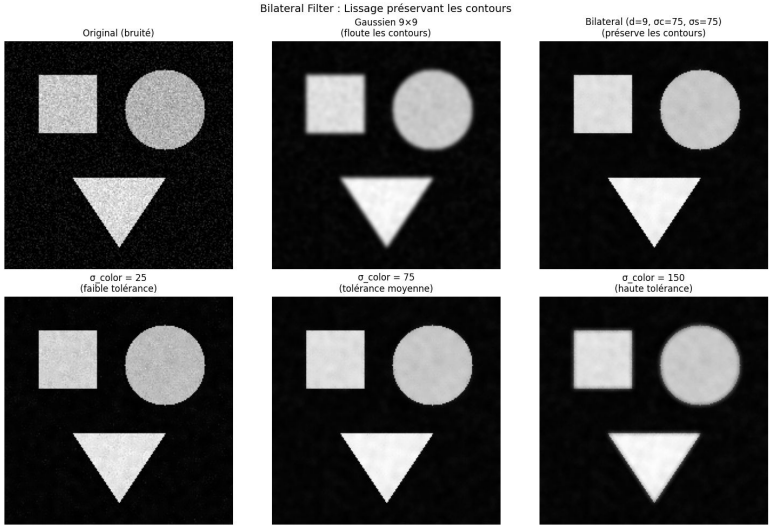

Principe

Lisse l'image **sans flouter les contours**.

Combine **deux pondérations** :

1. 1. **Spatiale** : pixels proches ont plus de poids (comme Gaussien)
2. 2. **Intensité** : pixels de valeur similaire ont plus de poids

$$BF(p) = \frac{1}{W_p} \sum_{q \in S} G_{\sigma_s}(\|p - q\|) \cdot G_{\sigma_r}(|I_p - I_q|) \cdot I_q$$

Où :

- G_{σ_s}: noyau gaussien spatial
- G_{σ_r}: noyau gaussien sur les intensités (range)
- W_p: facteur de normalisation

4.3 Amélioration du contraste

4.3.1 Normalisation (Min-Max Scaling)

Principe : Étire les intensités pour occuper toute la plage [0, 255]

Formule :

$$I_{norm}(x, y) = \frac{I(x,y) - I_{min}}{I_{max} - I_{min}} \times 255$$

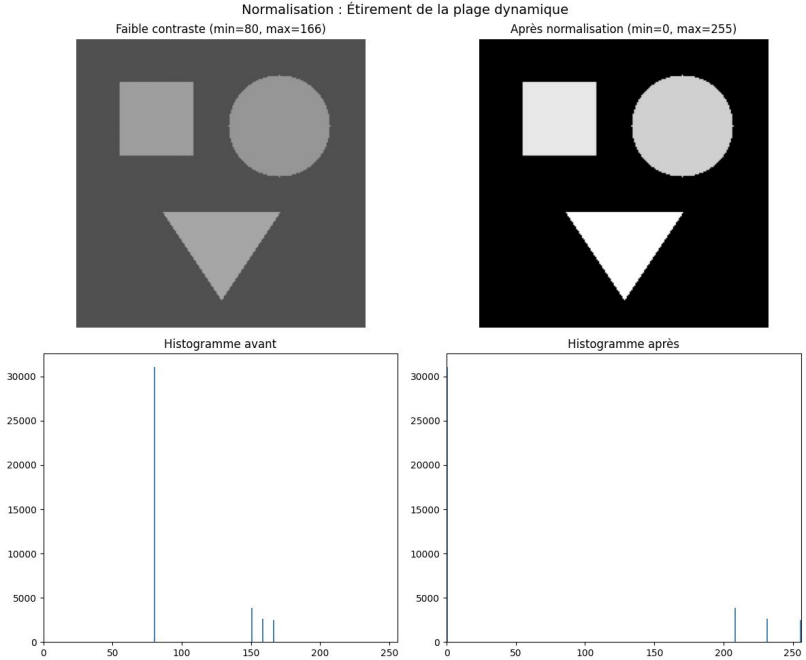

4.3.2 Histogram Equalization

Principe : Redistribue les intensités pour un histogramme uniforme via la CDF

Algorithme :

1. Calculer l'histogramme H(i)
2. Calculer la CDF (somme cumulative)
3. Utiliser CDF comme lookup table

Formule :

$$I_{eq}(x,y) = \text{round}\left(\frac{CDF(I(x,y)) - CDF_{min}}{M \times N - CDF_{min}} \times 255\right)$$

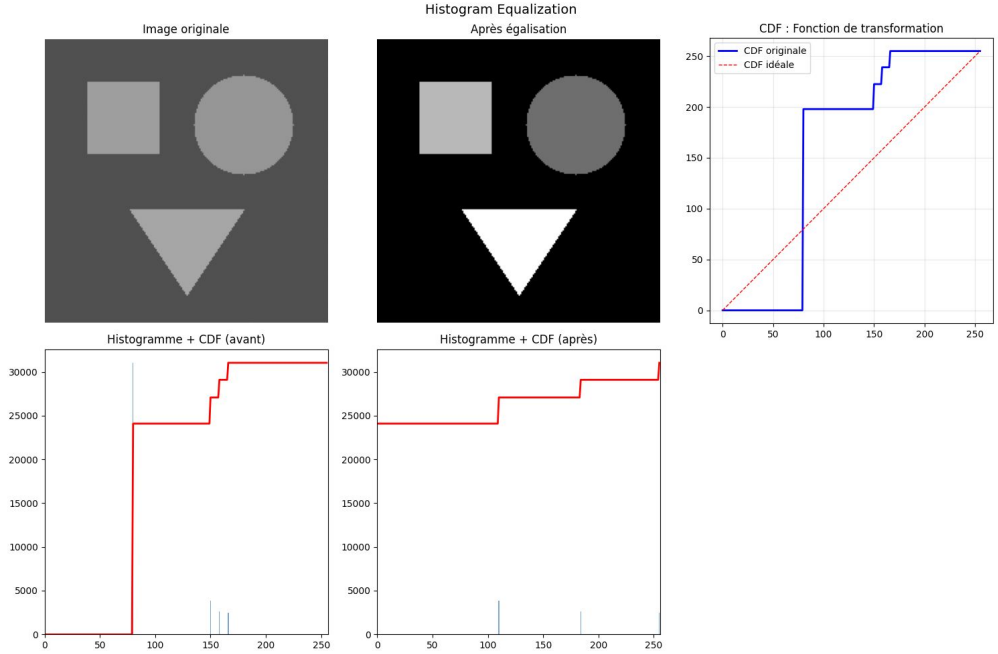

4.3.3 CLAHE (Contrast Limited Adaptive Histogram Equalization)

Principe : Égalisation LOCALE avec limitation de l'amplification

Algorithme :

1. Divise l'image en tuiles (ex: 8×8)
2. Applique l'égalisation sur chaque tuile
3. Limite l'amplification (clipLimit)
4. Interpole les frontières

Paramètre	Rôle	Valeur typique
clipLimit	Limite l'amplification	2.0 - 4.0
tileGridSize	Taille de la grille	(8, 8)

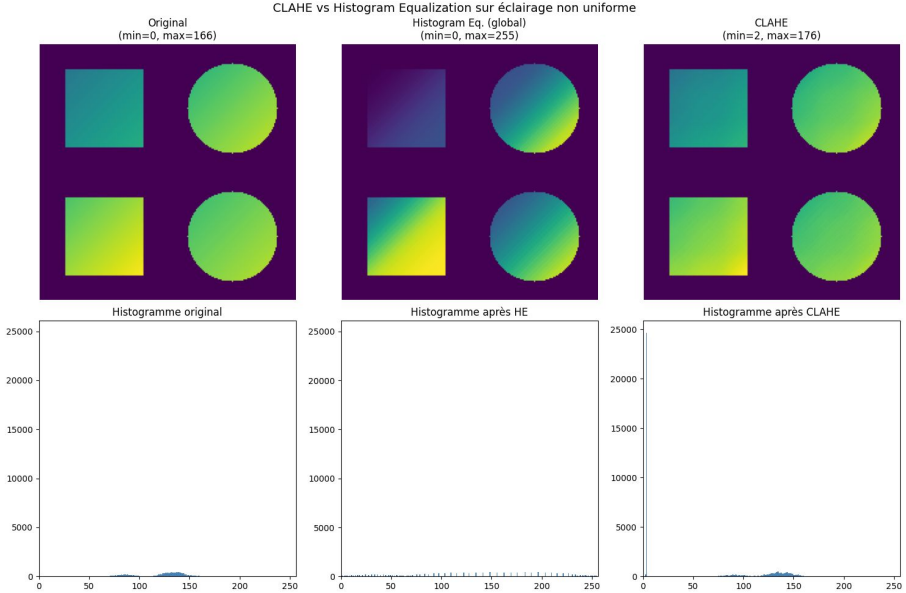

4.4 Binarisation (Segmentation simple)

4.4.1 Seuil global

La **binarisation** convertit une image en niveaux de gris en image binaire (noir/blanc uniquement).

$$I_{bin}(x,y) = \begin{cases} 255 & \text{si } I(x,y) > T \\ 0 & \text{sinon} \end{cases}$$

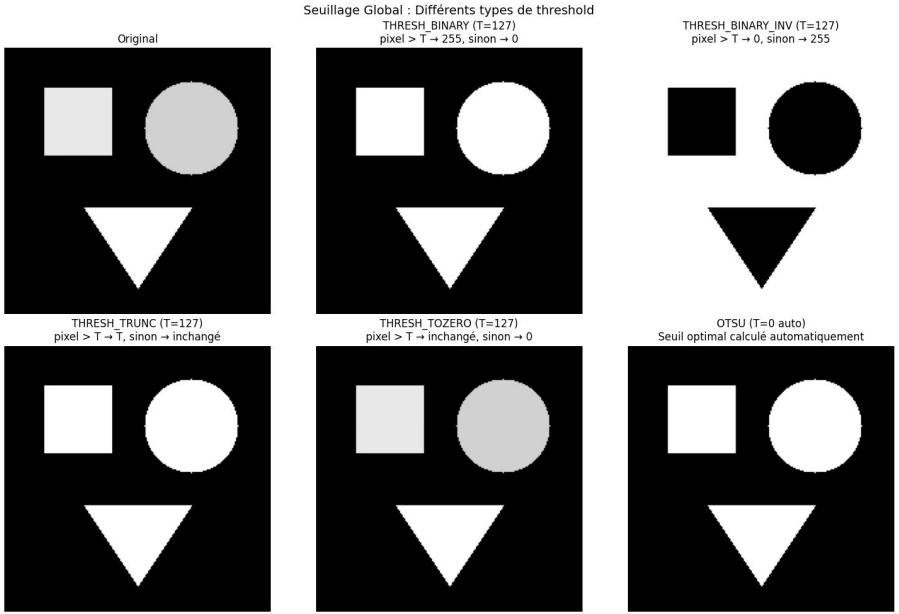

4.4.1 Méthode Otsu

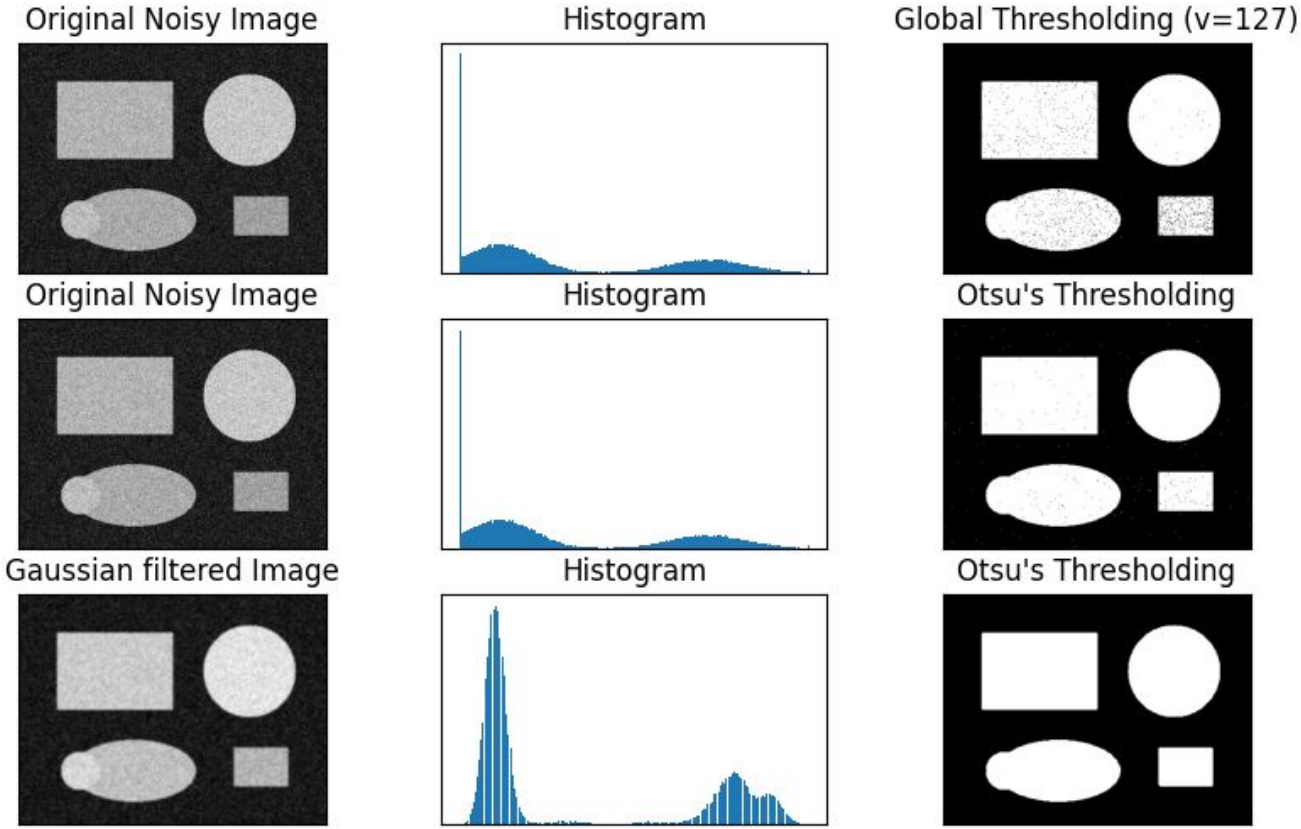

4.4.2 Seuil adaptatif (Adaptive Thresholding)

Le seuil T est calculé **localement** pour chaque pixel en fonction de son voisinage.

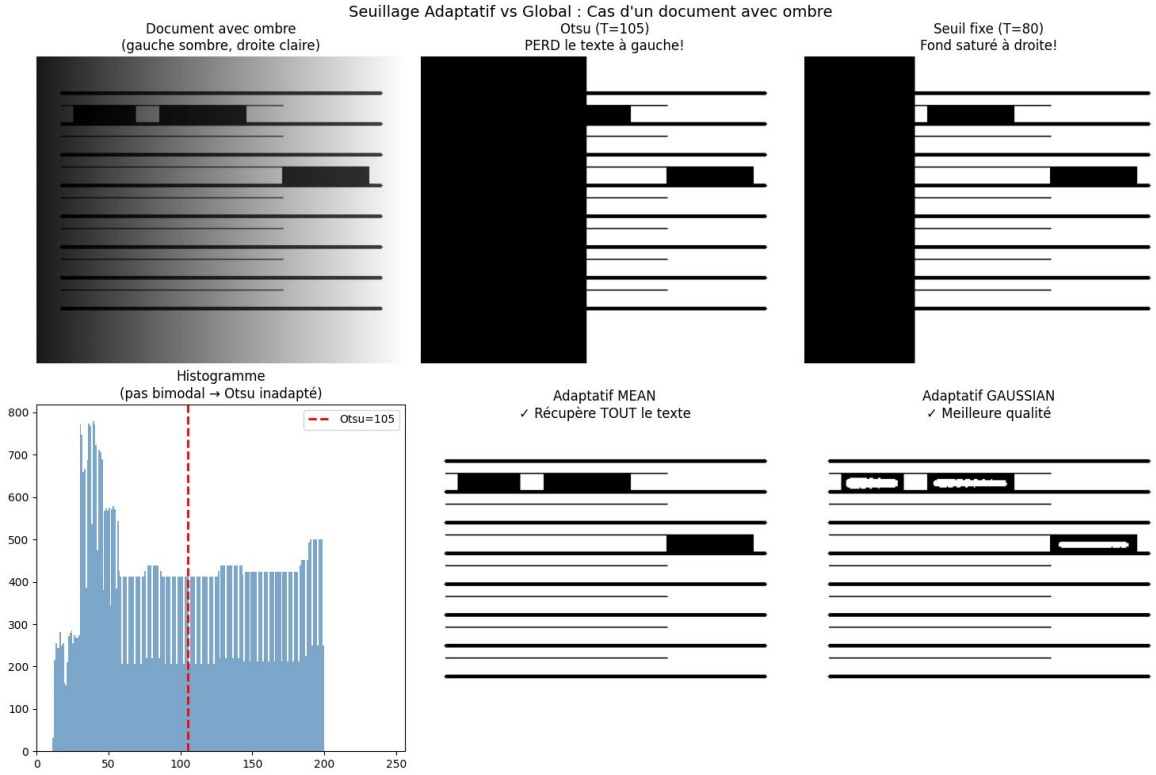

4.5 Opérations morphologiques

4.5.1 Érosion

Principe

Un pixel reste blanc (255) **uniquement si tous les pixels sous le kernel sont blancs**.

Effets

- Rétrécit les objets blancs
- Supprime les petits bruits (points isolés)
- Sépare les objets connectés par des liens fins

4.5.2 Dilatation

Principe

Un pixel devient blanc (255) si au moins un pixel sous le kernel est blanc.

Effets

- Élargit les objets blancs
- Comble les petits trous
- Connecte les objets proches

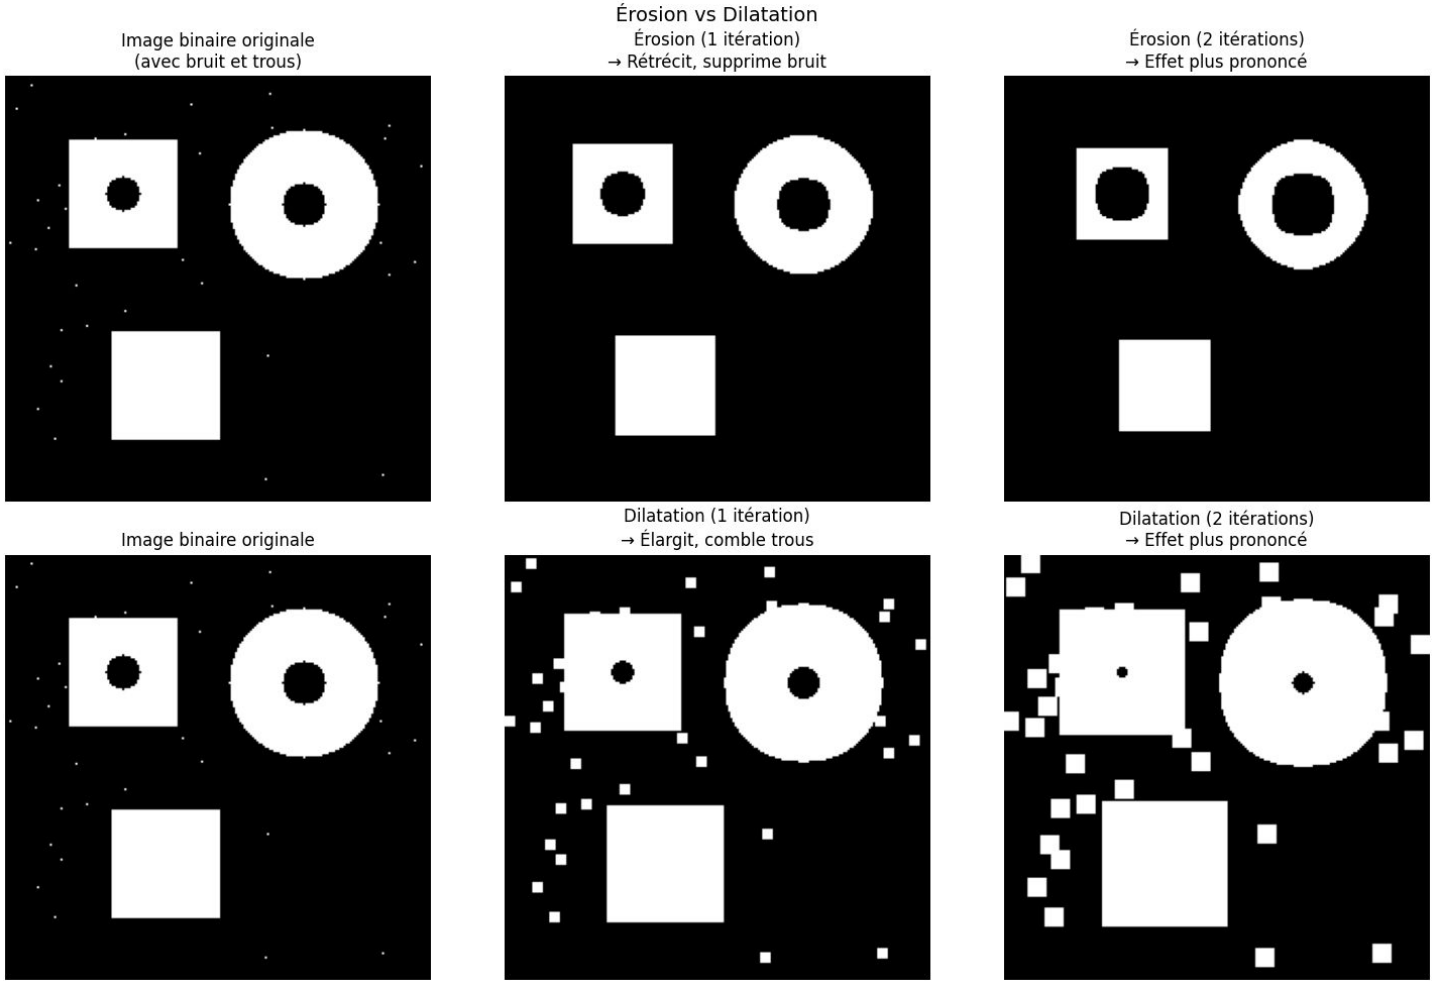
Érosion vs Dilatation
Image binaire originale
(avec bruit et trous)
Érosion (1 itération)
→ Rétrécit, supprime bruit
Érosion (2 itérations)
→ Effet plus prononcé
Image binaire originale
Dilatation (1 itération)
→ Élargit, comble trous
Dilatation (2 itérations)
→ Effet plus prononcé

4.5.3 Ouverture et Fermeture

Ouverture : érosion -> dilatation

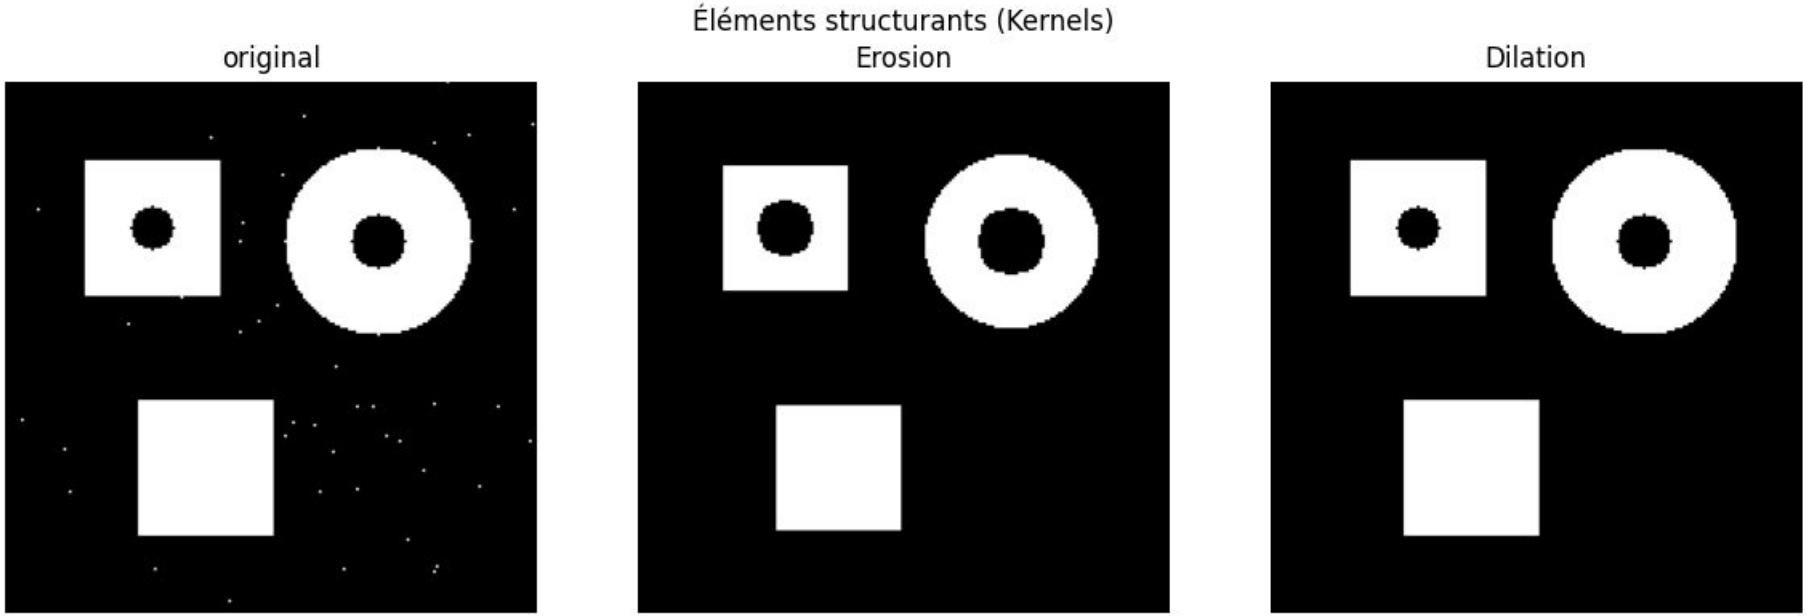

4.5.3 Ouverture et Fermeture

Fermeture : dilatation-> érosion

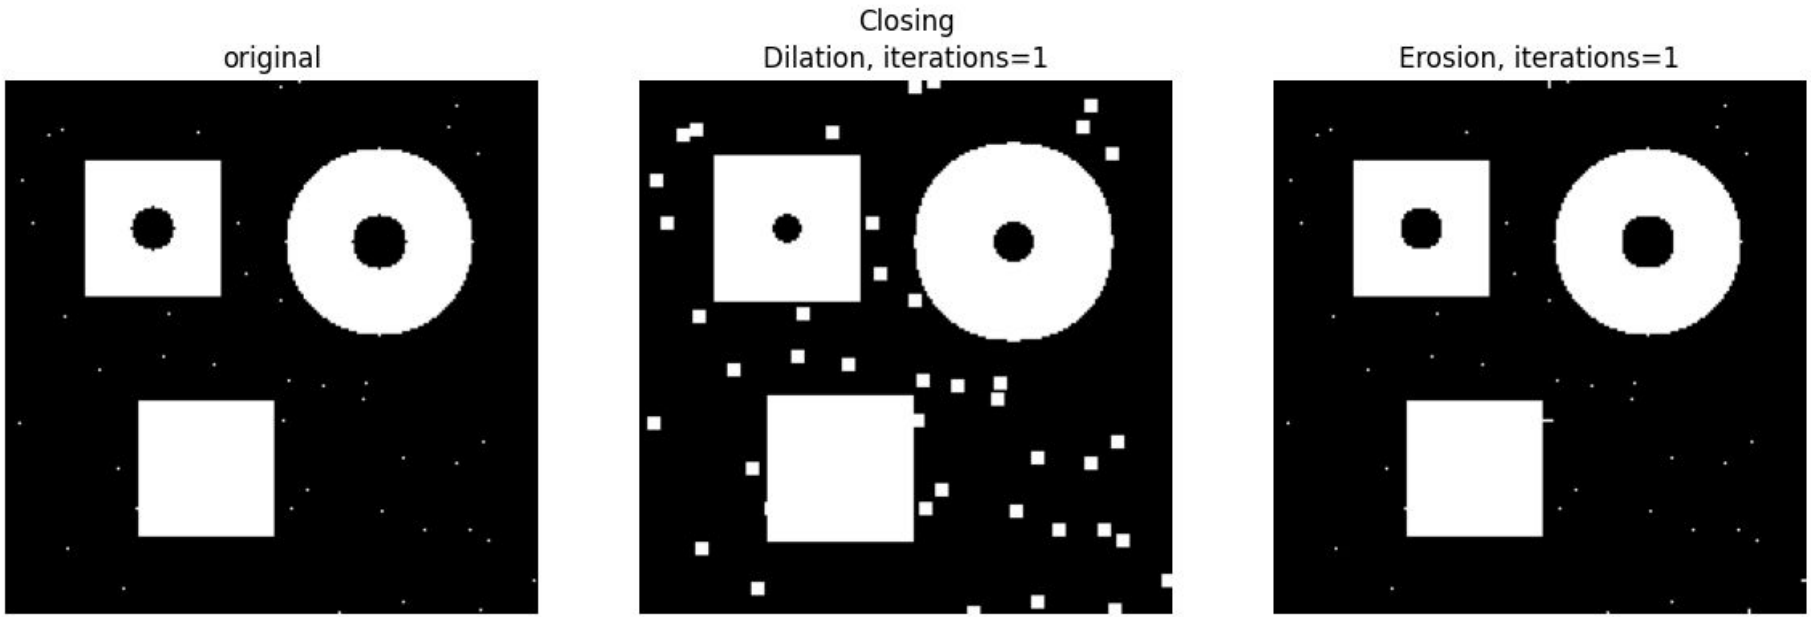

Opérations morphologiques composées

Original
(bruit + trous)

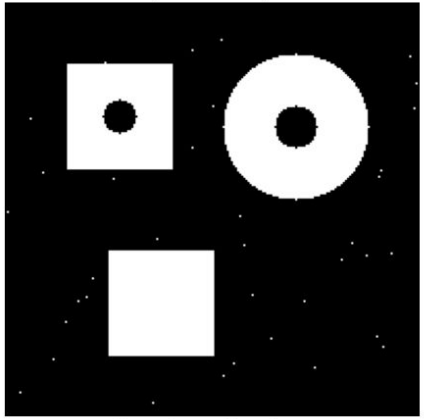

Ouverture (Érosion → Dilatation)
Supprime le bruit

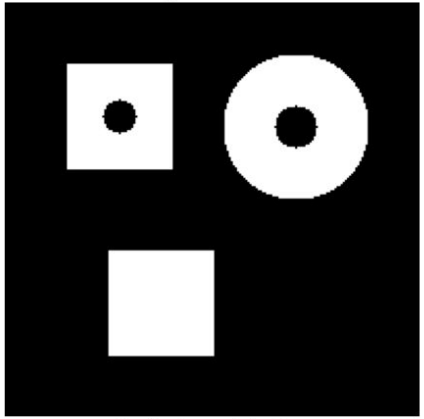

Fermeture (Dilatation → Érosion)
Comble les trous

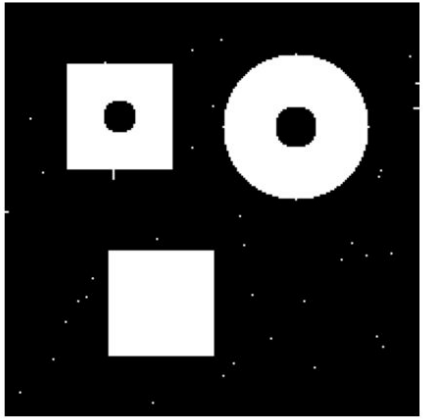

Ouverture + Fermeture
Nettoyage complet

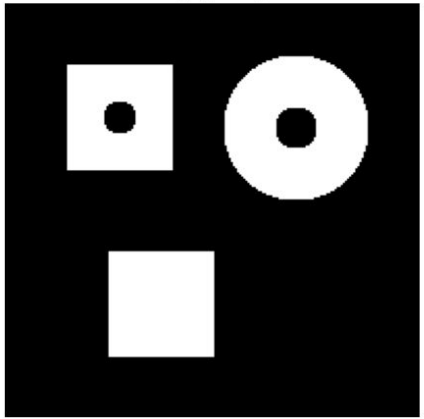

Gradient morphologique
(Dilatation - Érosion = Contours)

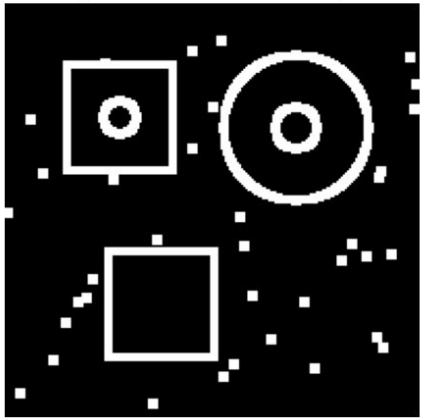

```
RÉSUMÉ DES OPÉRATIONS :

────────────────────────
Ouverture = Érosion + Dilatation
→ Supprime les petits objets/bruit
→ Préserve la taille des grands objets

────────────────────────
Fermeture = Dilatation + Érosion
→ Comble les petits trous
→ Connecte les objets proches

────────────────────────
Gradient = Dilatation - Érosion
→ Extrait les contours des objets
```

4.6 Détection de contours

4.6.1 Opérateurs de gradient (Sobel / Scharr)

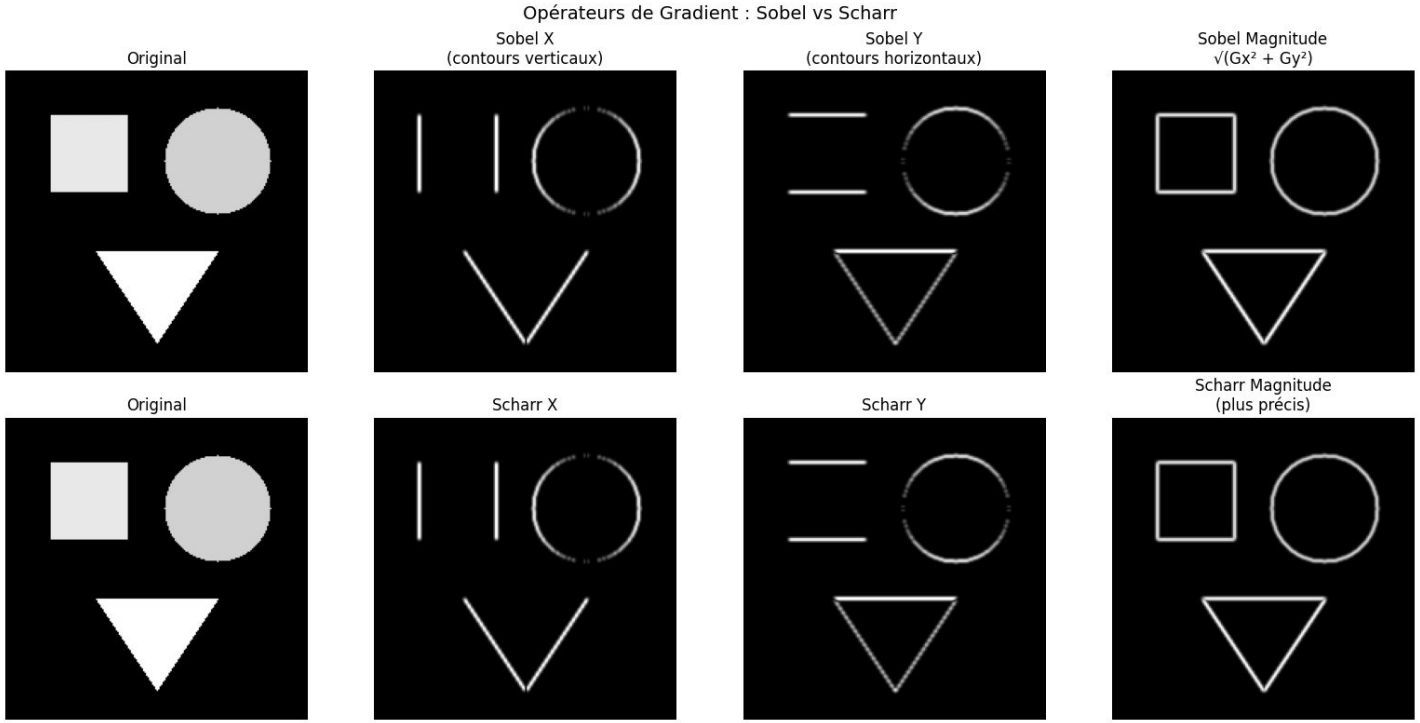

Noyaux de Sobel

Direction X (Gx)	Direction Y (Gy)
[-1 0 +1]	[-1 -2 -1]
[-2 0 +2]	[0 0 0]
[-1 0 +1]	[+1 +2 +1]

4.6.2 LAPLACIEN

Principe

Dérivée seconde de l'image : détecte les **passages par zéro** (zero-crossings).

Laplacien of Gaussian (LoG)

Combine lissage gaussien + Laplacien pour réduire la sensibilité au bruit.

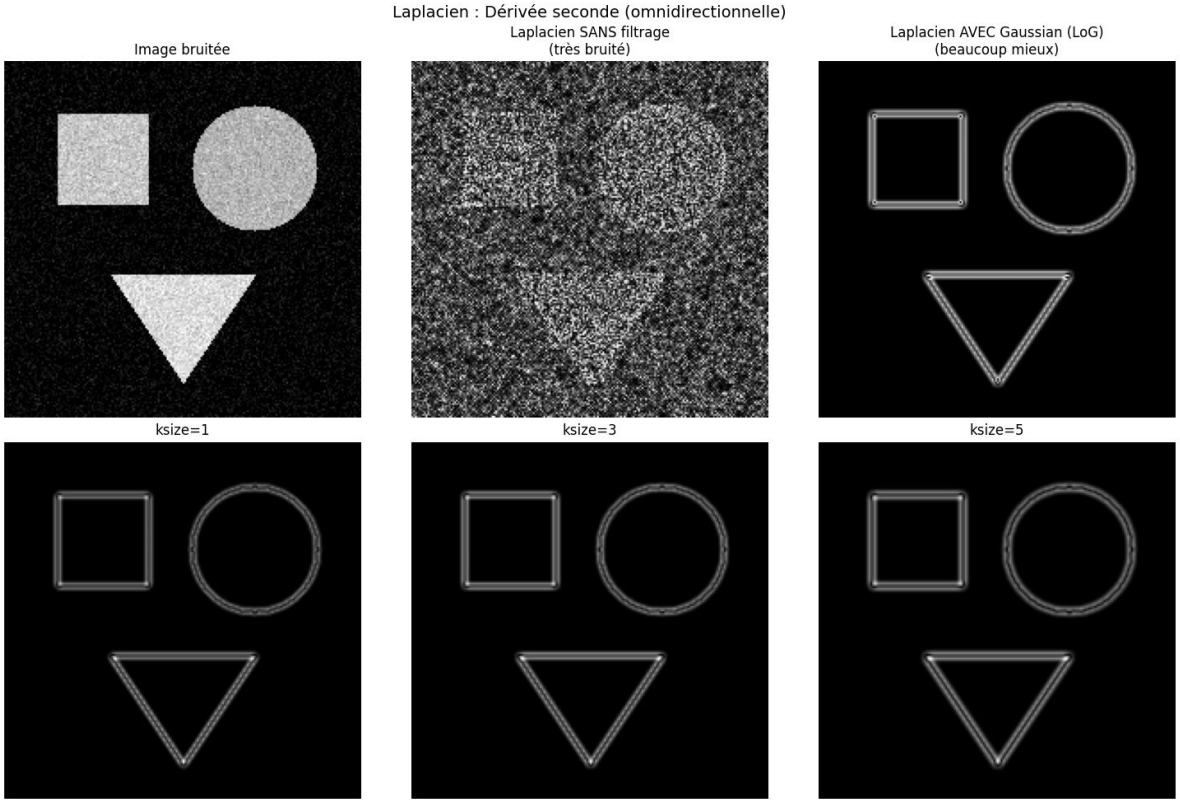

4.6.3 Canny

Algorithme multi-étapes considéré comme la **référence** pour la détection de contours.

Algorithme détaillé :

1. **Flou gaussien** : Réduit le bruit (empêche fausses détections)
2. **Gradient (Sobel) :** Calcule magnitude et direction
3. **Suppression non-maxima** : Affine les contours (1 pixel d'épaisseur)
4. **Double seuillage** : Sépare contours forts, faibles, non-contours
5. **Hystérésis** : Connecte contours faibles aux forts

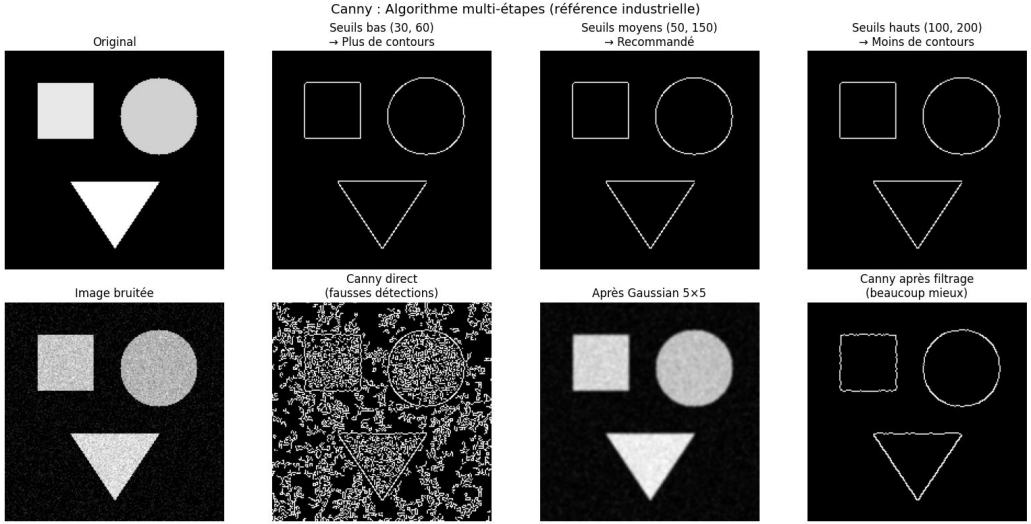

5. Pipeline recommandé

Image couleur

↓

Niveaux de gris

↓

Réduction du bruit (Gaussian / Median)

↓

Amélioration du contraste (CLAHE)

↓

Canny

↓

Opérations morphologiques

Cas	Prétraitements clés
OCR	Gris → CLAHE → Binarisation adaptative
Documents	Median → Threshold adaptatif
Objets industriels	Gaussian → Canny → Closing
Images bruitées	Bilateral → Canny