OCR détection et reconnaissance de texte

Computer Vision - Séance 3

Optical Character Recognition

Principe : convertir le texte présent **dans une image** en texte **numérique** exploitable

deux approches :

- **Détection** : localiser les zones de texte (lignes, mots, caractères) dans l'image.
- **Reconnaissance** : transcrire le contenu textuel des zones détectées.

Images OCR Text

BureauDepot Facture N° 755564F

Adresse : 15 allée des glaïeuls 49100 Angers

Tel : 02XXXXXXXX

Conditions légales de vente: implique paiement de la somme totale avant la date du 20 aout 2027, sous peine de poursuites juridiques

Désignation	Quantité	Prix HT	Montant TVA	Prix TTC	Total
Chaise de bureau	3	100,00€	20.00€	120.00€	360.00€
Pot à crayons	14	5.00€	1.00€	6.00€	84.00€
Tapis de souris	10	20.00€	4.00€	24.00€	240.00€

BureauDepot Facture N° 755564F

Adresse : 15 allée des glaïeuls 49100 Angers

Tel : 02XXXXXXXX

Conditions légales de vente: implique paiement de la somme totale avant la date du 20 aout 2027, sous peine de poursuites juridiques

Désignation	Quantité	Prix HT	Montant TVA	Prix TTC	Total
Chaise de bureau	3	100,00€	20.00€	120.00€	360.00€
Pot à crayons	14	5.00€	1.00€	6.00€	84.00€
Tapis de souris	10	20.00€	4.00€	24.00€	240.00€

Désignation ; quantité;Prix HT;Montant TVA;Prix TTC;Total
Chaise de bureau;3;100.00€;20.00€;120.00€;360.00€
Pot à crayons;14;5.00€;1.00€;6.00€;84.00€
Tapis de souris;10;20.00€;4.00€;24.00€;24.00€

Un large spectre d’application

- OCR de documents
  - Document scannée
  - Document manuscrit
  - PDF non “**Searchable**”
- OCR en environnement réel
  - Panneaux
  - Enseignes
  - Etiquettes

Modélisation

Tokenisation

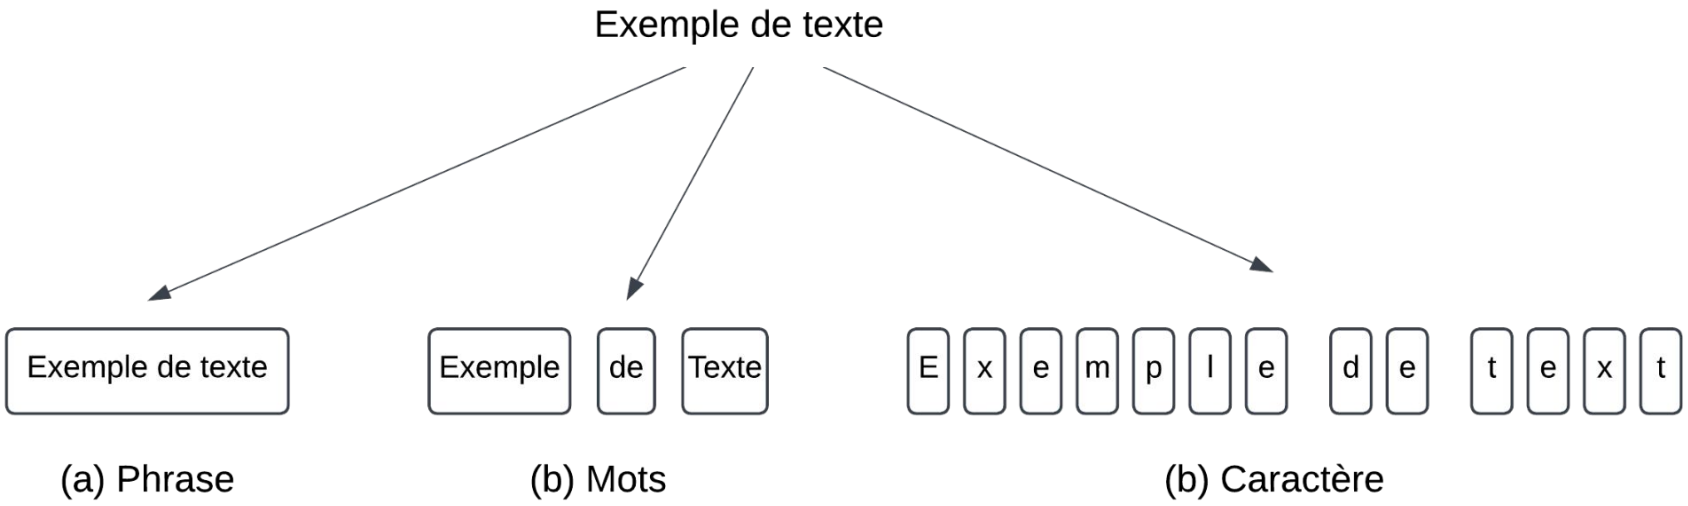

Vectorisation

On représente le sens des mots dans une espace en N-dimension

vectoriser, c'est traduire l'information du monde réel en nombres porteurs de sens pour que les machines puissent apprendre et raisonner dessus.

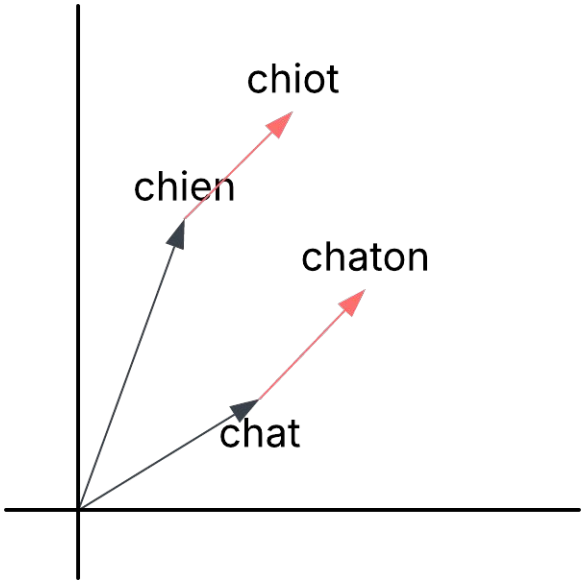

Erreurs et Métriques

Erreurs typiques

- Confusions visuelles :

  `O/0`, `I/l/1`, `S/5`, `B/8`.

- Erreurs de segmentation : caractères collés, mots coupés.
- Erreurs géométriques : texte incliné, perspective (un caractère “écrasé”).
- Bruit de fond : motifs, textures, faible contraste.

CER — *Character Error Rate*

Le **CER** mesure le taux d'erreur au niveau des caractères.

On utilise la distance d'édition (Levenshtein) :

$$CER = (S + D + I) / N$$

où :

- S = substitutions de caractères
- D = suppressions (*deletions*)
- I = insertions
- N = nombre de caractères dans la référence

WER — *Word Error Rate*

Le **WER** applique la même logique mais au niveau des mots :

$$WER = (S + D + I) / N$$

où *N* est ici le nombre de mots de la référence.

Quand utiliser quoi :

- **CER** : plus stable pour des langues/écritures où la segmentation en mots est délicate, ou pour du texte court.
- **WER** : plus parlant pour des documents orientés “lecture” (phrases), mais sensible à la tokenisation (ponctuation, apostrophes, etc.).

Ce que CER/WER ne disent pas (métriques métier)

Exemples :

- O/0 sur identifiant = critique
- 1 erreur sur une date peut invalider le champ

Comment spécifier l’évaluation de nos méthodes :

- Field validity rate (regex / règles) : date, IBAN, TVA, montant
- Accuracy chiffres-only (codes, montants)
- Détection : précision / rappel / IoU sur boîtes

Logique

Chaîne OCR complète

1. Acquisition
2. Prétraitements (améliorer la lisibilité)
3. Détection de texte **(EAST/CRAFT)**
4. Regroupement par ordre de lecture
5. Rectification des crops
6. Reconnaissance **(CRNN/CTC ou Transformers)**
7. Post-traitements **(lexiques, formats)**
8. Validation

Prétraitements : quand et pourquoi

Les prétraitements sont utiles quand ils réduisent la variabilité inutile :

- Correction de perspective : photos de documents (smartphone) où les lignes ne sont plus horizontales.
- Deskew : scan légèrement incliné (quelques degrés suffisent à faire baisser la reconnaissance).
- Contraste : texte gris clair sur fond clair.

Ordre de lecture

L’OCR ne s’arrête pas à “reconnaître des boîtes”. Il faut souvent reconstruire une lecture :

- documents multi-colonnes
- tableaux
- champs dispersés (factures)

Post-traitements

Une grande part de la qualité perçue vient des post-traitements :

- lexiques : liste de produits, villes, codes
- formats : dates, montants, IBAN
- validation : score de confiance + règles

Pour chaque erreur typique, il faut se demander ce qui peut causer cette erreur : détection, crop, normalisation, modèle ? Et voir si on peut le résoudre avec une solution de post traitement.

Méthodes de détection

NMS (Non-Maximum Suppression)

lorsqu’un détecteur produit **plusieurs boîtes** qui se recouvrent pour le **même** mot/ligne, on veut ne garder que la meilleure.

Réglage clé : le **seuil NMS**.

- - Seuil faible → on supprime agressivement → risque de perdre des boîtes proches (rappel diminue).
- - Seuil élevé → on supprime peu → risque de doublons (précision diminue) et post-traitement plus difficile.

EAST (*Efficient and Accurate Scene Text detector*)

Il produit une **carte** de présence de texte et des **paramètres géométriques** pour reconstruire des boîtes.

Points forts :

- Efficace en inférence (souvent utilisé en production)
- Simple à intégrer

Limites :

- Gère moins bien le texte **très courbe**
- La qualité dépend fortement des seuils et du post-traitement (NMS)

CRAFT (*Character Region Awareness for Text detection*)

Il estime des cartes de probabilité pour :

- régions de caractères
- affinités entre caractères (pour regrouper en mots/lignes)

Points forts :

- Très bon pour du texte **irrégulier**, **densité variable**, et peut mieux gérer le “texte naturel”
- Permet un regroupement plus précis

Limites :

- Plus coûteux
- Le post-traitement (regroupement) est plus complexe

Détection : EAST vs CRAFT (que choisir?)

EAST

- + rapide, simple, souvent prod-friendly
- - moins à l’aise sur texte courbe, dépend des seuils + NMS

CRAFT

- + granularité caractère + affinités, mieux sur texte irrégulier
- - plus coûteux, post-traitement plus complexe

Méthodes de reconaissance

CNN

Dans une image de texte, une fois que le CNN a extrait des **features visuelles**, on obtient souvent une **séquence de vecteurs** le long de l'axe horizontal (de gauche à droite).

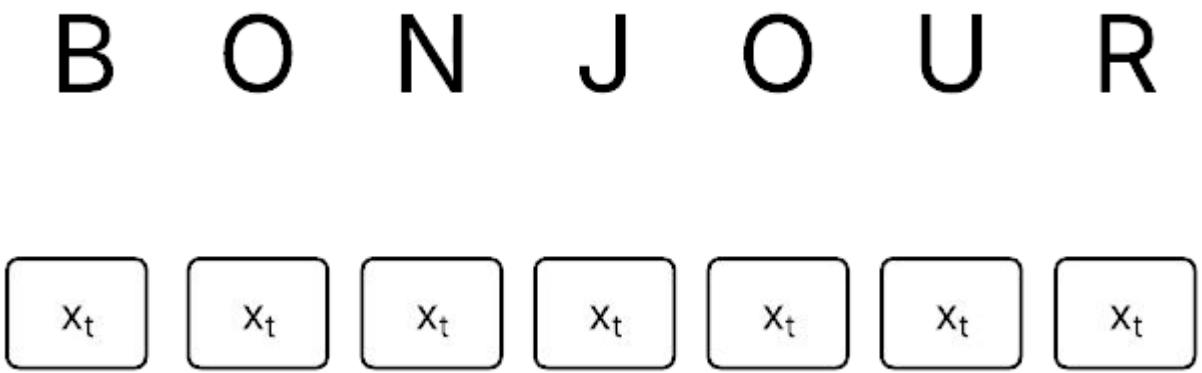

CRNN (Convolutional Recurrent Neural Network)

Objectif : reconnaître un mot/une ligne de texte dans un crop image en produisant une séquence de caractères.

B O N J O U R

Pourquoi c'est adapté à l'OCR :

- le texte est une struct
- le CNN gère la variabi

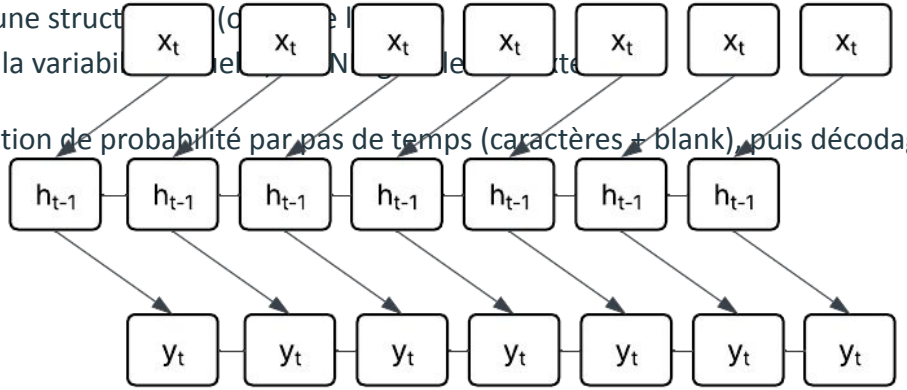

Sortie : une distribution de probabilité par pas de temps (caractères + blank), puis décodage (greedy/beam)

BiLSTM : pourquoi “bi-directionnel” aide en OCR

B O N J O U R

RNN avec “mémoire” (gère mieux les dépendances longues que RNN simple)

BiLSTM = 2 LSTM :

- un lit la séquence gauche → droite
- l’autre lit droite → gauche

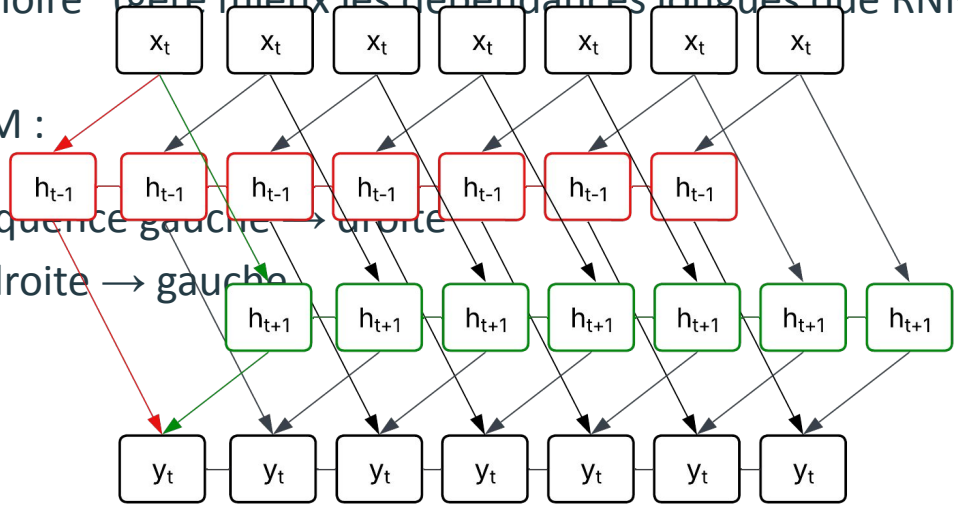

CTC (Connectionist Temporal Classification)

CTC permet d’entraîner le modèle **sans alignement explicite**.
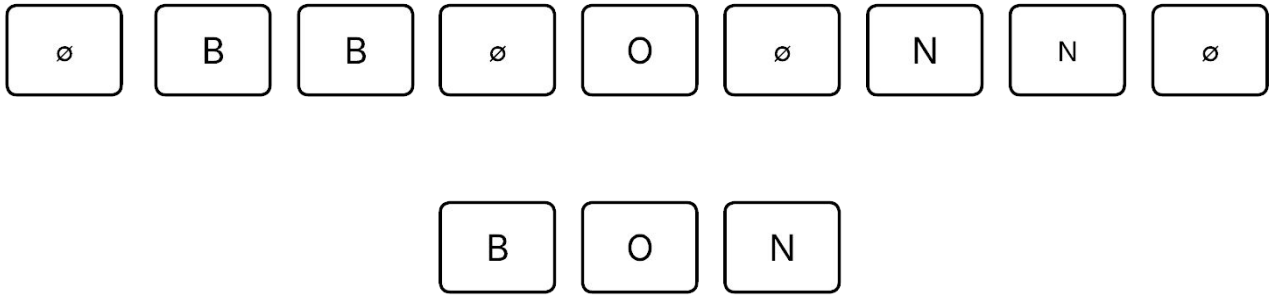
B O N